บทที่ 1
บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ประเทศไทยกำลังก้าวเข้าสู่สังคมผู้สูงอายุโดยสมบูรณ์ ซึ่งทำให้สัดส่วนของประชากรผู้สูงอายุเพิ่มขึ้นอย่างต่อเนื่อง ปัญหาด้านสุขภาพและความปลอดภัยของผู้สูงอายุจึงกลายเป็นวาระแห่งชาติ ซึ่งการล้ม (Fall) ถือเป็นสาเหตุหลักของการบาดเจ็บอย่างรุนแรงและเป็นภัยคุกคามต่อการดำรงชีวิตอิสระ โดยเฉพาะผู้ที่อาศัยอยู่ตามลำพัง ข้อมูลจากรายงานขององค์การอนามัยโลก (WHO) และกรมควบคุมโรคระบุว่า กว่า 1 ใน 3 ของผู้สูงอายุที่มีอายุ 60 ปีขึ้นไปมีความเสี่ยงต่อการหกล้มในแต่ละปี โดยส่วนใหญ่มีสาเหตุมาจากปัจจัยทางร่างกาย เช่น การทรงตัวไม่ดี กล้ามเนื้ออ่อนแรง และปัญหาด้านสายตา รวมถึงปัจจัยด้านสิ่งแวดล้อมในบ้าน เช่น พื้นลื่นหรือแสงสว่างไม่เพียงพอ แม้จะมีโครงการเชิงพฤติกรรมในชุมชนเพื่อป้องกันการล้ม แต่ยังขาดเทคโนโลยีที่ช่วยตรวจจับและแจ้งเตือนเหตุการณ์ล้มได้แบบอัตโนมัติและทันเวลา โดยทั่วไปเทคโนโลยีตรวจจับการล้มแบ่งออกเป็นหลายแนวทาง ได้แก่

1) สมาร์ตโฟน (Smartphone-based) ใช้เซนเซอร์ภายในโทรศัพท์มือถือเพื่อวิเคราะห์การเคลื่อนไหวและการล้ม

2) อุปกรณ์สวมใส่ (Wearable-based) ใช้มาตรวัดความเร่ง (Accelerometer) และไจโรสโคป (Gyroscope) ในโมดูลเซนเซอร์วัดความเฉื่อย (IMU Sensor) สำหรับจำแนกท่าทาง

3) ระบบอินเทอร์เน็ตของสรรพสิ่ง (IoT Systems) ใช้การเชื่อมต่ออินเทอร์เน็ตเพื่อส่งสัญญาณแจ้งเตือน อย่างไรก็ตาม ระบบตรวจจับการล้มที่กล่าวมามักมีข้อจำกัดด้านต้นทุนที่สูงและต้องพึ่งพาการประมวลผลบนคลาวด์ (Cloud Computing) ซึ่งอาจส่งผลให้เกิดความหน่วง (Latency) ที่ไม่เหมาะสมต่อการแจ้งเตือนเหตุฉุกเฉิน และไม่เอื้อต่อการใช้งานในกลุ่มผู้สูงอายุในพื้นที่ชนบท โครงงานนี้จึงมุ่งพัฒนาอุปกรณ์ตรวจจับการล้มต้นทุนต่ำ โดยใช้ไมโครคอนโทรลเลอร์ขนาดเล็ก (ESP32) ที่สามารถฝังแบบจำลองปัญญาประดิษฐ์ขนาดเล็ก (TinyML) เพื่อประมวลผลในตัวอุปกรณ์แบบออฟไลน์

ระบบอาศัยการเรียนรู้ของเครื่อง (Machine Learning) เพื่อจำแนกพฤติกรรมการเคลื่อนไหวจากข้อมูลเซนเซอร์ IMU ซึ่งเป็นรากฐานสำคัญของเทคนิคปัญญาประดิษฐ์ฝังตัว (Embedded AI) ที่โครงงานนี้นำมาประยุกต์ใช้ นอกจากนี้ เพื่อให้เกิดการตอบสนองอย่างรวดเร็ว โครงงานยังได้บูรณาการกลไกการส่งสัญญาณแจ้งเตือนเฉพาะพื้นที่ (Acoustic & BLE Beacon) ระบบระบุพิกัดแบบผสมผสาน และกลยุทธ์ฐานข้อมูลแบบผสมผสาน (Hybrid Database) เพื่อจัดการข้อมูลผู้ใช้อย่างมีประสิทธิภาพ

ดังนั้น โครงงานนี้จึงมีความสำคัญในการสร้างนวัตกรรมต้นทุนต่ำที่สามารถช่วยลดความเสี่ยงและยกระดับคุณภาพชีวิตของผู้สูงอายุ รวมทั้งต่อยอดเป็นต้นแบบเทคโนโลยีด้านการดูแลสุขภาพอัจฉริยะสำหรับสังคมผู้สูงอายุ (Smart Healthcare for Aging Society) ได้ในอนาคต

1.2 วัตถุประสงค์ของโครงงาน

1.2.1 เพื่อพัฒนาอุปกรณ์ตรวจจับการล้มต้นทุนต่ำที่ใช้เทคโนโลยีปัญญาประดิษฐ์ฝังตัว

1.2.2 เพื่อสร้างและฝึกโมเดล TinyML สำหรับจำแนกเหตุการณ์การล้มจากข้อมูลเซนเซอร์ IMU

1.2.3 เพื่อออกแบบและนำกลยุทธ์ฐานข้อมูลแบบผสมผสาน (Hybrid Database) มาใช้ในการจัดการข้อมูลที่มีโครงสร้างสูง (SQL) และข้อมูลแบบเวลาจริง (NoSQL) อย่างมีประสิทธิภาพ

1.2.4 เพื่อประเมินความแม่นยำและความรวดเร็วของการตรวจจับแบบเรียลไทม์บน ไมโครคอนโทรลเลอร์

1.3 สมมติฐาน

1.3.1 การสกัดคุณลักษณะเชิงลึก 18 มิติ (18-Dimensional Feature Extraction) ทางสถิติและชีวกลศาสตร์จากสัญญาณความเร่งและไจโรสโคป ร่วมกับโมเดลโครงข่ายประสาทเทียม MLP (18→32→16→1) จะสามารถจำแนกเหตุการณ์การล้มออกจากกิจกรรมประจำวัน (ADL) ได้อย่างมีนัยสำคัญ โดยให้อัตราการตรวจจับการล้มถูกต้อง (Sensitivity / Recall) บนชุดข้อมูลทดสอบไม่น้อยกว่าร้อยละ 95.00 และความแม่นยำรวม (Accuracy) ไม่น้อยกว่าร้อยละ 95.00

1.3.2 การแปลงโมเดลให้อยู่ในรูปโค้ดภาษา Native C++ Forward Pass จะสามารถประมวลผลบนไมโครคอนโทรลเลอร์ ESP32 ได้ด้วยเวลาประมวลผล (Inference Latency) ไม่เกิน 5.0 มิลลิวินาที และใช้หน่วยความจำ Flash ไม่เกิน 15 KB โดยสามารถทำงานจำแนกเหตุการณ์การล้มได้แบบออฟไลน์อย่างสมบูรณ์แม้ไม่มีสัญญาณเครือข่ายอินเทอร์เน็ต

1.3.3 การประยุกต์ใช้เกณฑ์ตัดสินใจความมั่นใจที่ระดับร้อยละ 80 (Confidence Threshold ≥ 0.8) ร่วมกับตัวกรองแรงกระแทกทางกายภาพ (Physical Impact Guard >1.8g) จะสามารถลดอัตราการแจ้งเตือนลวง (False Alarm) จากกิจกรรมประจำวันแบบรวดเร็วได้อย่างมีประสิทธิภาพ โดยไม่สูญเสียความสามารถในการตรวจจับการหกล้มจริง

1.3.4 การบูรณาการระบบระบุตำแหน่งแบบคู่ (Dual Positioning: GPS NEO-7M และ Wi-Fi Geolocation) ร่วมกับเสียงสัญญาณไซเรน (Acoustic Beacon) บนตัวเครื่อง จะช่วยให้ผู้ดูแลสามารถระบุพิกัดและเข้าถึงตัวผู้สูงอายุที่ประสบเหตุได้ทั้งพื้นที่กลางแจ้งและภายในอาคาร

1.4 ข้อตกลงเบื้องต้น

1.4.1 อุปกรณ์ตรวจจับการล้มจะถูกติดตั้งและสวมใส่ไว้ที่บริเวณเอวหรือลำตัว ของผู้ใช้งานในตำแหน่งระนาบที่มั่นคง เพื่อให้แกนการวัดของเซ็นเซอร์สะท้อนการเคลื่อนไหวของจุดศูนย์ถ่วงของร่างกาย ได้อย่างถูกต้องตรงตามการฝึกสอนของแบบจำลอง

1.4.2 การทดสอบภาคสนามจำลองการล้มใช้อาสาสมัครที่มีสุขภาพร่างกายแข็งแรงและทำการล้มลงบนเบาะนิรภัย ตามหลักจริยธรรมความปลอดภัย โดยยอมรับว่าค่าแรงกระแทกอาจมีการลดทอนลงจากแรงซับของเบาะเมื่อเทียบกับการล้มกระแทกพื้นแข็งจริง

1.4.3 จำนวนท่าทางในการเก็บรวบรวมข้อมูลประกอบด้วย ท่าการหกล้ม 5 ท่า และท่ากิจวัตรประจำวัน (ADL) 6 ท่า เก็บข้อมูลซ้ำท่าละ 5 รอบ จากกลุ่มอาสาสมัครจำนวน 20 คน

1.5 ขอบเขตของโครงงาน

1.5.1 ใช้ไมโครคอนโทรลเลอร์ ESP32 และเซนเซอร์ IMU (MPU6050)

1.5.2 ใช้ TinyML (TensorFlow Lite for Microcontrollers) สำหรับสร้างและฝังโมเดล Machine Learning ลงในบอร์ด ESP32 เพื่อจำแนกเหตุการณ์การล้มและการเคลื่อนไหวปกติ (ADL) แบบออฟไลน์ (On-device Processing) ประเมินความสามารถของโมเดลตามเกณฑ์หลัก ได้แก่ ความแม่นยำ (Accuracy), ความไว (Recall), และเวลาตอบสนอง (Latency)

1.5.3 ใช้โมดูลระบุพิกัดดาวเทียม (GPS NEO-7M) ร่วมกับระบบระบุตำแหน่งผ่าน Wi-Fi (Wi-Fi Geolocation) เพื่อระบุตำแหน่งที่เกิดเหตุและคำนวณข้อมูลกิจกรรมการเดินด้านสุขภาพ

1.5.4 ใช้กลยุทธ์ Hybrid Database ในการจัดการข้อมูลใช้ SQL (MySQL/ PostgreSQL) ร่วมกับ Prisma สำหรับการจัดเก็บข้อมูลผู้ใช้หลัก (User Profile) และบันทึกเหตุการณ์การล้มถาวร (Event Logs) ใช้ NoSQL เช่น Firebase สำหรับการจัดเก็บข้อมูลที่มีการเปลี่ยนแปลงบ่อย เช่น ข้อความแชท (Chat Session) และสถานะอุปกรณ์แบบ Real-time

1.5.5 เก็บข้อมูลการล้มและการเคลื่อนไหวปกติ (ADL) จากอาสาสมัครทั่วไปที่มีอายุ 20–40 ปี เพื่อจำลองการล้มอย่างปลอดภัย และใช้ข้อมูลนี้ในการฝึกโมเดล AI

1.5.6 ฝึกโมเดลและฝังในบอร์ด ประเมินความแม่นยำ (Accuracy), ความไว (Recall), และเวลาตอบสนอง (Latency)

1.6 ตัวแปรที่ศึกษา

1.6.1 ตัวแปรต้น (Independent Variables)

1.6.1.1 รูปแบบกิจกรรมและการเคลื่อนไหวทางชีวกลศาสตร์

กลุ่มเหตุการณ์การหกล้ม (Fall Events) การล้มไปข้างหน้า (Forward Fall), การล้มไปข้างหลัง (Backward Fall), การล้มตะแคงซ้าย (Lateral Left Fall), การล้มตะแคงขวา (Lateral Right Fall), และการล้มแนวดิ่ง/ทรุดตัว (Vertical Fall)

กลุ่มกิจกรรมประจำวันปกติ (ADL Events) การเดินปกติ, การเดินเร็ว, การวิ่งเหยาะ, การลุก-นั่งเก้าอี้ปกติ, การนั่งกระแทกเก้าอี้เร็ว, การทิ้งตัวลงนอนบนเตียง, การเดินขึ้น-ลงบันได, การก้มเก็บของที่พื้น, และการไอ/จามขณะยืน

1.6.1.2 แบบจำลองการทำเหมืองข้อมูลที่ใช้จำแนก (Classification Algorithms) Decision Tree, k-Nearest Neighbors (k-NN), Naive Bayes, และ Multi-Layer Perceptron (MLP)

1.6.1.3 ระดับเกณฑ์ความมั่นใจในการตัดสินใจ (Decision Threshold) ค่าเกณฑ์มาตรฐานที่ระดับ 0.50 เปรียบเทียบกับค่าเกณฑ์ปรับปรุงที่ระดับ 0.80

1.6.2 ตัวแปรตาม (Dependent Variables)

1.6.2.1 ประสิทธิภาพความถูกต้องในการจำแนกประเภทของโมเดล

ค่าความถูกต้องแม่นยำรวม (Accuracy)

ค่าความไว / อัตราการตรวจจับการล้มถูกต้อง (Sensitivity / Recall)

ค่าความจำเพาะต่อกิจกรรมปกติ (Specificity)

ค่าความแม่นยำของการแจ้งเตือน (Precision)

ค่าคะแนนฮาร์โมนิกเฉลี่ย (F1-Score)

ค่าพื้นที่ใต้เส้นโค้ง ROC (Area Under the Curve: AUC)

1.6.2.2 ประสิทธิภาพการทำงานจริงบนฮาร์ดแวร์ไมโครคอนโทรลเลอร์ (Edge Performance Metrics)

ระยะเวลาในการทำนายผลของโมเดลบนชิป

ขนาดการใช้พื้นที่หน่วยความจำของบอร์ด

ระยะเวลาในการส่งสัญญาณแจ้งเตือนฉุกเฉินออนไลน์

อัตราความสำเร็จในการแจ้งเตือนเหตุฉุกเฉินภาคสนาม

อัตราความถูกต้องในการระบุทิศทางการล้ม

ความคลาดเคลื่อนของพิกัดระบุตำแหน่งภูมิศาสตร์

1.7 ประโยชน์ที่คาดว่าจะได้รับ

1.7.1 ลดอัตราการบาดเจ็บและเสียชีวิตการตรวจจับการล้มได้เร็วช่วยให้ผู้สูงอายุได้รับการช่วยเหลือ ทันเวลา

1.7.2 ลดระยะเวลาการช่วยเหลือและภาวะแทรกซ้อนการแจ้งเตือนอัตโนมัติช่วยป้องกันการนอนอยู่ กับพื้นเป็นเวลานาน

1.7.3 ลดภาระของผู้ดูแลและครอบครัวระบบอัตโนมัติช่วยให้ผู้สูงอายุสามารถดำรงชีวิตอิสระได้มาก ขึ้น และสร้างความมั่นใจให้กับญาติ

1.7.4 ได้องค์ความรู้ในการประยุกต์ใช้กลยุทธ์ Hybrid Database (SQL/Prisma และ NoSQL) เพื่อจัดการข้อมูลผู้ใช้ที่มีโครงสร้าง (User Profile) และข้อมูลสถานะแบบ Real-time (Chat Session, Device Status) ได้อย่างมีประสิทธิภาพและยืดหยุ่น

1.7.5 การพัฒนาอุปกรณ์ต้นทุนต่ำที่ใช้ Embedded AI ซึ่งสามารถผลิตและขยายผลเป็นผลิตภัณฑ์เชิงพาณิชย์ในประเทศได้จริง เพื่อตอบโจทย์สังคมสูงวัย

1.7.6 ช่วยลดค่าใช้จ่ายทางด้านการรักษาพยาบาลฉุกเฉินและลดภาระของระบบสาธารณสุขโดยรวม

1.8 นิยามศัพท์เฉพาะ

1.8.1 TinyML (Tiny Machine Learning) เทคโนโลยีการนำโมเดลปัญญาประดิษฐ์และการเรียนรู้ของเครื่อง (Machine Learning) ที่ผ่านการบีบอัดและปรับแต่งให้มีขนาดเล็กมาก มา

ประมวลผลและทำนายผลบนชิปไมโครคอนโทรลเลอร์ที่มีหน่วยประมวลผลและหน่วยความจำจำกัด ในระดับกิโลไบต์หรือเมกะไบต์ได้โดยตรงแบบ On-Device

1.8.2 IMU (Inertial Measurement Unit) โมดูลเซ็นเซอร์ตรวจวัดความเฉื่อยและการเคลื่อนไหว ประกอบด้วยเครื่องวัดความเร่ง (Accelerometer) สำหรับวัดแรงโน้มถ่วงและความเร่งเชิงเส้น 3 แกน (a_x, a_y, a_z) และไจโรสโคป (Gyroscope) สำหรับวัดอัตราการเปลี่ยนแปลงความเร็วเชิงมุมในการหมุนตัว 3 แกน (g_x, g_y, g_z)

1.8.3 MLP (Multi-Layer Perceptron) สถาปัตยกรรมโครงข่ายประสาทเทียมแบบป้อนตรง (Feedforward Artificial Neural Network) ที่ประกอบด้วยชั้นนำเข้า (Input Layer), ชั้นซ่อน (Hidden Layers) อย่างน้อย 1 ชั้นขึ้นไป และชั้นส่งออก (Output Layer) ซึ่งสามารถเรียนรู้ความสัมพันธ์แบบไม่เป็นเชิงเส้น (Non-linear Mapping) ของข้อมูลได้

1.8.4 ADL (Activities of Daily Living) กิจวัตรและการเคลื่อนไหวปกติในชีวิตประจำวันของมนุษย์ เช่น การเดิน, การวิ่งเหยาะ, การนั่งเก้าอี้, การยืน, การนอน, การก้มเก็บของ และการขึ้น-ลงบันได ซึ่งนำมาใช้เป็นคลาสควบคุม (Negative Class / Label 0) ในการฝึกสอนโมเดล

1.8.5 Freefall Ratio คุณลักษณะทางชีวกลศาสตร์ที่แสดงสัดส่วนของตัวอย่างข้อมูลในหน้าต่างเวลาที่ขนาดความเร่งรวมลดลงต่ำกว่า 0.3 g ซึ่งสะท้อนถึงสภาวะการลอยตัวไร้น้ำหนักขณะร่างกายเริ่มร่วงหล่นลงสู่พื้น

1.8.6 Impact Ratio คุณลักษณะทางชีวกลศาสตร์ที่แสดงสัดส่วนของตัวอย่างข้อมูลในหน้าต่างเวลาที่ขนาดความเร่งรวมพุ่งสูงเกินกว่า 3.5 g ซึ่งสะท้อนถึงแรงกระแทกเฉียบพลันเมื่อร่างกายปะทะกับพื้นผิว

1.8.7 Jerk อัตราการเปลี่ยนแปลงของความเร่งเทียบกับเวลา ($\frac{\Delta a}{\Delta t}$) ใช้ตรวจวัดความฉับพลันของการกระชากตัวและการเปลี่ยนความเร็วของร่างกายอย่างกะทันหันขณะเสียการทรงตัว

1.8.8 Inference Latency ระยะเวลาที่โมเดลปัญญาประดิษฐ์ใช้ในการคำนวณ Forward Pass ทางคณิตศาสตร์ เพื่อแปลงข้อมูลอินพุตขนาด 1 หน้าต่างข้อมูลให้กลายเป็นผลลัพธ์ความน่าจะเป็นของการล้ม มีหน่วยเป็นมิลลิวินาที (ms)

1.8.9 Hybrid Database Strategy กลยุทธ์การออกแบบระบบจัดเก็บข้อมูลแบบผสมผสาน โดยใช้ฐานข้อมูลเชิงสัมพันธ์ (Relational SQL) สำหรับข้อมูลที่มีโครงสร้างแน่นอนและต้องการความสมบูรณ์ของธุรกรรม ร่วมกับระบบจัดเก็บข้อมูลแบบ NoSQL / Time-Series Documents และ Flash NVS Key-Value Store สำหรับรองรับสตรีมมิ่งข้อมูลเซ็นเซอร์ความถี่สูงและการเก็บข้อมูลออฟไลน์

1.8.10 Acoustic Beacon สัญญาณเสียงไซเรนจากลำโพง Buzzer บนตัวเครื่องอุปกรณ์ ที่ส่งเสียงเตือนอย่างต่อเนื่องทันทีเมื่อตรวจพบการล้ม เพื่อทำหน้าที่เป็นประภาคารเสียงนำทางในระยะรัศมี 30–50 เมตร ช่วยให้ผู้ช่วยเหลือค้นหาตำแหน่งของผู้สูงอายุที่อยู่ในมุมอับสายตาได้อย่างรวดเร็ว

1.8.11 Alarm Fatigue ภาวะความล้าทางจิตวิทยาของผู้ดูแลและผู้สูงอายุที่เกิดจากระบบแจ้งเตือนส่งสัญญาณเตือนลวง (False Alarm) บ่อยครั้งเกินไปจนนำไปสู่ความรำคาญ การละเลยสัญญาณเตือน หรือการปิดระบบทิ้ง ซึ่งแก้ไขได้ด้วยการตั้งค่าเกณฑ์ตัดสินใจ (Threshold) ที่เข้มงวดและการติดตั้งปุ่มกดยกเลิกฉุกเฉิน